

Beslutningslogg - Omsorg 2050 / Framskrivningsverktøy

Dette er en samlet, begrunnet logg over de viktigste valgene som er tatt i dette prosjektet: datakilder, metodevalg, funn under validering, og feilrettinger. Formålet er at noen som tar over eller viderefører prosjektet skal forstå HVORFOR ting er gjort som de er gjort, ikke bare hva koden gjør (det står i kodekommentarene). For de statistiske modellenes formler og estimeringsdetaljer, se tekniskdokumentasjon.md.

1. Datakilder og datainnhenting (`hent_paneldata_2007_2025.R`)

- **Datakilde:** SSBs PxWebApi (statistikkbanken), både vo (POST, px-json-format) og v2 (GET, JSON-stat2), avhengig av hva som fungerer best for den enkelte tabellen.
- **Tabelloversikt:**
 - `04686` (t.o.m. 2016) + `12292` (f.o.m. 2015): Y1a (hjemmetjeneste- brukere), Y2 (*heldøgnsbolig*), Y4 (timer/uke)
 - `11645` (2009-2025): Y3a (institusjon, langtidsopphold) - aldersoppløst per tjenestetype, krever ingen skjøting
 - `04686` + `11924` (2015-2023) + `14534` (2015-2025): Y_5 (sykepleier- årsverk)
 - `07459` (2005-2026, `agg_KommSummer`): befolkning etter alder/kjønn - allerede en sammenslått tidsserie fra SSB
 - `12882`: befolkningsframskrivninger (brukes i `framskriv_*.R`)
- **Historisk kommunekode-harmonisering:** `07459` bruker SSBs egen sammenslåtte kodeliste (`agg_KommSummer`, "K"-prefiks) og er derfor allerede i dagens (2024) kommunestruktur. De andre tabellene (`04686`, `12292`, `11924`, `12882`, `11645`) har IKKE dette - løsningen er å hente full kommunehistorikk og for hver tabell prøve alle historiske koder for en 2024-kommune, og beholde den/de som faktisk finnes/har data i tabellen.
- **Tabell `11645` dekker bare 2009-2025:** et forsøk på å hente 2007-2008 ga HTTP 400 (SSB avviser hele forespørselen hvis ÉN kode er ugyldig for en dimensjon). Løst med et årsfilter (`years[years >= 2009]`) ved kallet.
- **Sammenslåtte kommuner (`lag_2024_struktur()`):** valgte å slå alle historiske kommuner sammen til dagens (2024) kommunestruktur FØR modellering, i stedet for å modellere på historisk struktur og konvertere etterpå. Prinsipp:
 - Antallsvariabler (brukere, beboere, årsverk) **summeres** over kildekommunene.
 - `Y_4` (timer/uke, som allerede er et snitt) tas som et **vektet snitt** av kildekommunenes verdier, vektet med kildekommunens `Y_1_a_ialt` (antall hjemmetjenestemottakere) - IKKE folketall, fordi folketallet fra `07459` allerede er den sammenslåtte 2024-kommunens tall og derfor identisk på hver kildekommune-rad (å vekte med det ville gitt et reelt uvektet snitt).

- Befolkningskolonnene tas fra FØRSTE rad per kommune-år (ikke summeres), av samme grunn som over - de er allerede den fulle summen.
- **Bug funnet og rettet:** `y_5` (årsverk) ble feilaktig vektet-snittet som `y_4`, selv om årsverk er en additiv størrelse (ikke et snitt). Flyttet til `SUM_KOLONNER`. Data regenerert fra allerede lagrede mellomresultater (ingen nye SSB-kall nødvendig). Effekt: betydelig for store sammenslåtte kommuner, f.eks. Drammen (0220+0627+0628) 2019 endret fra 210 til 460 årsverk - den gamle metoden underrapporterte kraftig for slike kommuner.
- **Datadekning,** `y_5`: mangler HELT for 2007-2014 (100 % manglende alle disse årene) - reell dekning er 2015-2025, kortere enn de andre variablene. Ikke undersøkt videre hvorfor `04686` ikke bidro med data så langt tilbake for denne variabelen, selv om kildelisten i koden opprinnelig antydte det.
- **2010-anomali i** `y_1`: stikkprøver i Halden og Eigersund viste et brått ~90 % fall i `y_1_a_ialt` i ALLE aldersgrupper i 2010, med full gjenoppretting i 2011 - tolket som en rapporteringsfeil (sannsynligvis knyttet til en IPLOS-versjonsovergang nevnt i `04686` s metadata), ikke en reell endring i tjenestebruk. **2010 er derfor utelatt fra `y_1`-modelleringen. ** Sjekk EKSPLOSITT for `y_2` / `y_3` / `y_4` og IKKE funnet der - 2010 er beholdt for disse variablene. Ikke bekreftet systematisk for alle 357 kommuner, bare stikkprøver.

2. Demensprevalensestimering (`legg_til_demens.R`)

- Bruker aldersgruppe- og kjønns spesifikke prevalensrater (fra brukerens opprinnelige `dementia_dic`), multiplisert med ETTÅRIG befolkning (alder x kjønn) fra `07459` og summert til kommune x år.
- Krever et FULLSTENDIG datasett (alle 106 aldersgrupper x 2 kjønn = 212 rader) for at et kommune-år skal regnes som "komplett" - hvis ikke, settes estimatet til NA i stedet for å regne på et ufullstendig grunnlag.
- ** `demensandel` (andel av befolkningen), ikke råttallet `demens_estimert`, brukes som forklaringsvariabel i alle modeller** - et råttall ville i stor grad bare fanget opp kommunestørrelse, som allerede er representert andre steder i modellene (eksponering/offset).

3. Valg av modellstruktur per variabel

- `y_1` (hjemmetjenestebrukere) og `y_2*` (heldøgns omsorg): Poisson GLMM (log-lenke, befolkning som eksponering/offset, tilfeldig kommuneintercept, årsummyer, `demensandel`) - naturlig valg siden begge er heltallige brukerantall som skalerer med befolkning.
- `y_4` (timer/uke): lineær blandet modell (`lmer`), IKKE Poisson - `y_4` er allerede et gjennomsnitt (ikke et antall), så en tellemodell med log-lenke og befolkningseksponering gir ikke mening.
- `y_5` (sykepleierårsverk): log-lineær blandet modell (`lmer`) på

`log(Y_5)` med befolkning som offset) - årsverk skalerer med kommunestørrelse på samme måte som `Y_1/Y_2*`, men er ikke heltallig, så ren Poisson er ikke strengt egnet. Valgt som en pragmatisk mellomting: samme multiplikative populasjonsskalering som Poisson-modellene, men med normalfordelte feil på logskala.

- **Y_3 (institusjon, langtidsopphold):** ikke modellert separat ennå - inngår i dag bare som del av `Y_2*`.

- **Tilfeldig helning vs. kun tilfeldig intercept:** testet konsekvent for

ALLE variabler (korrelert og ukorrelert helning på `demensandel` per kommune).

Helningsvariantene gir konsekvent bedre AIC/BIC og ofte bedre kryssvalidert treffsikkerhet, MEN gir en betydelig andel kommuner med en implausibel NEGATIV effektiv helning (fast + tilfeldig) på `demensandel`

- dvs. modellen ville antatt at FLERE med demens gir FÆRRE

brukere/årsverk i disse kommunene. Andeler med negativt fortegn (korrelert variant): 91/357 (`Y_1`), 95/355 (`Y_2*`), 195/357 (`Y_4`), 103/357 (`Y_5`). **Beslutning: bruk ALLTID hovedmodellen (kun tilfeldig intercept) for faktisk framskrivning**, uansett bedre passform for helningsvarianten - risikoen for et absurd fortegn utenfor det historisk observerte området vurderes som viktigere enn litt bedre in-sample/CV-passform. Helningsvariantene beregnes og lagres likevel, for diagnostisk fullstendighet. **OPPDATERT (se punkt 9):** denne policyen er senere reversert for FRAMSKRIVNING (ikke for kryssvalideringen over, som fortsatt er gyldig akkurat som beskrevet) - en ankringsmetode gjør det trygt å bruke helningsmodellen likevel, og løser samtidig en reell inkonsistens-bug.

- **Kryssvalideringsmetode:** leave-one-year-out (LOYO) for alle modeller

- modellen trenes på alle år UTENOM ett, og evalueres på det utelatte

året. Årsdummy-modeller kan per definisjon ikke ha en egen koeffisient for et år de ikke er trent på - dette løses med en forenkling: gjennomsnittet av de ANDRE årenes estimerte årseffekt brukes som stand-in for det utelatte året. Dokumentert eksplisitt som en tilnærming, ikke en eksakt løsning.

4. Forsøk som ble forkastet/satt på vent

- `Y_4` + `Y_1_a_ialt` som ekstra forklaringsvariabel: testet på

eksplisitt oppfordring (rå antall hjemmetjenestemottakere, ikke som andel). Resultat: ingen meningsfull forbedring i kryssvalidert treffsikkerhet (korrelasjon ~0,735 med og uten), og `demensandel`'s koeffisient byttet fortegn (ble negativ) når `Y_1_a_ialt` ble lagt til - et tegn på kollinearitet med kommunestørrelse, akkurat som forhåndsvarslet i kodekommentaren. **Besluttet å IKKE ta denne varianten videre nå** - kan revurderes senere, se `skript/modell_y4.R`.

5. Framskrivning (`framskriv_y1.R`, `framskriv_y2_stjerne.R`, `framskriv_y5.R`)

- Bruker SSBs befolkningsframskrivning, **kun hovedalternativet MMMM**

(tabell 12882) foreløpig - LLML/HMH og Telemarksforskning sine framskrivninger er planlagt (se punkt 6, "Om"-fanens veikart), men ikke implementert.

- **Årseffekt for framtidige år:** satt til gjennomsnittet av de

historiske årseffektene, av samme grunn som i kryssvalideringen (en årsdummy-modell har ingen egen koeffisient for et år utenfor treningsdataene).

- **Glidende overgang** (`glatt_overgang()`) fra observert til

modellbasert nivå, for å unngå brå hopp i grafene ved overgangen fra historikk til framskrivning: 90 % vekt på observert 2025-verdi i 2026, lineært avtagende utover. Se tekniskdokumentasjon.md for eksakt formel. **OPPDATERT:** opprinnelig nådde vekten 0 % (100 % modell) allerede i 2036, men dette ga et synlig KINK i grafene (brukeren observerte det for Y_1 og Y_2^*) - fordi vekten hadde en konstant, negativ helning fram til 2036 og deretter flat null, en diskontinuitet i STIGNINGSTALLET akkurat ved brytpunktet. Rettet ved å strekke overgangen over HELE framskrivningsperioden (2026-2050) i stedet for bare de første 10 årene - vekten når nå 0 % først ved siste framskrevne år.

Avveining bevisst akseptert: observert 2025-nivå har nå en god del gjenværende vekt langt inn i perioden (f.eks. ~45-50 % ved 2036, mot 0 % før), dvs. mindre av trajectorien er "ren" kryssvalidert modellframskrivning - men brukeren vurderte dette som et akseptabelt bytte mot å fjerne kinken, siden det uansett er en etterbehandlingsmessig glatting, ikke en endring av selve den statistiske modellen.

- **Duplisert kode** mellom `framskriv_y1.R` / `framskriv_y2_stjerne.R` /

`framskriv_y5.R` i stedet for en delt hjelpefil - et bevisst valg for å unngå regresjonsrisiko på allerede fungerende kode. Vurder en felles hjelpefil hvis flere Y-variabler gjør duplikasjonen upraktisk å vedlikeholde.

- **Kommunespesifikk trend (i appen, ikke i de faste framskriv_*.R-filene):**

en brukerstyrt funksjon i `app.R` (`framskriv_trend()`) som tolker den tilfeldige helningen på `demensandel` per kommune som en kommunespesifikk TREND (f.eks. lokal politikk), og lar brukeren velge hvor mange år ($T = 0-10$) denne trenden skal fases lineært ut over, før framskrivningen går over til det nasjonale gjennomsnittet. Bygget først for Y_1 alene ("først vil jeg se hvordan resultatet ser ut"), deretter generalisert til Y_2^*/Y_5 med samme mekanisme (én generisk funksjon parametrisert på variabel-ID, i stedet for tre kopier - i tråd med app.R sin egen etablerte "variabel-agnostisk"-stil, se punkt 6, i motsetning til skript/-filenes bevisste duplisering). Skrus på med en avkryssingsboks (AV som standard, slik at eksisterende oppførsel/usikkerhetsbånd ikke endres for noen som ikke aktivt velger dette). Se punkt 9 for en reell bug som ble funnet og rettet i forbindelse med denne funksjonen, og for hvorfor `hovedmodell_slope` nå brukes for ALL framskrivning (ikke bare når trend-bryteren er på).

6. Shiny-appen (`app.R`)

- `app.R` må ligge i prosjektrøten (Shiny-krav for `runApp()`).

- **Kritisk bug funnet og rettet:** Shiny sin `runApp()` kjører automatisk

ALLE `.R`-filer i prosjektrøten og i `R/`-mappen som "helper files" ved oppstart - dette kjørte ved et uhell hele datainnhentingsskriptet (25-minutters SSB-henting for 357 kommuner) hver gang appen startet. Løst ved å flytte alle frittstående arbeidsflyt-script til en egen `skript/`-mappe, som Shiny

ikke skanner.

- **Variabel-agnostisk design:** én sentral `Y_VARIABLER`-liste med metadata (kolonnenavn, filnavn, 2010-flagg) per variabel - resten av appen (kommuneutvalg, plott, tabell, nedlasting) er felles kode som leser fra denne listen. Gjør det enkelt å legge til en ny Y-variabel uten å endre UI/plott/tabell-logikk (gjort for `Y_2*` og `Y_5`).
- **Ingen metodikk/modelldetaljer skal vises i appen selv** - "Om"-fanen er bevisst forenklet til å IKKE avsløre hvilken modelltype, hvilke formler eller hvilke script som brukes, slik at eksterne brukere av appen ikke kan se nøyaktig hvordan framskrivningene beregnes. Fullstendig metodedokumentasjon finnes i stedet i tekniskdokumentasjon.md, som ikke er en del av selve appen. **Datakilder er et unntak:** "Om"-fanen lister likevel opp hvilke SSB- statistikkbank-tabeller (04686, 12292, 11645, 11924, 14534, 07459, 12882) som ligger til grunn - dette regnes ikke som å avsløre MODELLERINGSMETODIKK (statistikkbank-tabellnumre er offentlig informasjon, ikke prosjektets egen analyse), og er nyttig åpenhet for brukere/veiledere om hvor tallene kommer fra.
- **Variabelnavn i UI:** standardisert til mønsteret "Etterspørsel etter X (enhet)" for alle tre variabler ("hjemmetjenester (brukere)", "bolig (brukere)", "sykepleier (avtalte årsverk)") - mer beskrivende for en ekstern leser enn de opprinnelige "Y1"/"Y2*"/"Y_5"-navnene, som ikke betyr noe utenfor prosjektets egen kode. "Avtalte årsverk" er SSBs egen presise betegnelse (til forskjell fra "utførte årsverk", som også korrejerer for fravær) - brukt her i stedet for det mer generiske "årsverk".
- **Planlagt videre arbeid (se "Om"-fanen):** lagt til et konkret veikart-punkt om å estimere TILBUD (ikke bare etterspørsel) av sykepleiere, med metodikk fra SSBs rapport "Behov for og tilgang på arbeidskraft i offentlig helse og omsorg fremover" (RAPP 2026/18), samt å inkludere LLML- og HHMH-befolkningsframskrivninger fra SSB og befolkningsframskrivninger fra Telemarksforskning som alternativ til SSBs hovedalternativ MMMM. Ingen av disse er påbegynt - kun notert som neste steg.

7. Datavalidering underveis

- Historisk `Y_1` plottet mot SSBs rådata for Halden og Eigersund (senere generalisert til å fungere for alle kommuner) for å bekrefte at den sammensatte tidsserien (skjøttet fra flere kilde-tabeller) er korrekt før modellering startet.
- `lag_2024_struktur()` manuelt verifisert mot Nordre Follo-sammenslåingen (Ski + Oppegård) for å bekrefte at summering/vekting av sammenslåtte kommuner regnes riktig.
- Leave-one-year-out kryssvalidering brukt konsekvent som hovedmetode for å vurdere modellenes prediktive treffsikkerhet, i tillegg til AIC/BIC-sammenligning og eksplisitt sjekk av "feil fortegn" på `demensandel`-helningen per kommune.

8. Kvantifisering av usikkerhet (Bayesiansk bootstrap)

- **Metode:** kommune-vis Bayesiansk bootstrap - én Dirichlet(1,...,1)-vekt

per kommune per iterasjon (samme vekt for alle år i kommunen, siden kommunen er den egentlige "enheten" i panelstrukturen), brukt som presisjonsvekt i en refit av hovedmodellen, med samme framskrivnings- og glidende-overgang-logikk som punkttestimatet. Kjørt for Y1, Y2* og Y_5 (60 iterasjoner hver, se `usikkerhet_*.R`).

- **Bevisst valg: ikke lagre enkeltiterasjonene** - bootstrap-utvalgene

holdes kun i en midlertidig matrise i minnet, og BARE 2,5/97,5- persentilene (95 %-intervallet) skrives til disk. Unngår å bygge opp store mellomresultatfiler for noe som uansett bare skal oppsummeres.

- **Vektskalering:** en rå Dirichlet(1,...,1)-trekning summerer til 1 (hver

vekt $\sim 1/K$). Brukt direkte som `weights` i `glmer` / `lmer` ville dette kunstig blåst opp den estimerte variansen (weights tolkes som presisjonsvekter, ikke sannsynlighetsvekter). Skalert opp med K slik at vektene i gjennomsnitt er 1 - endrer ikke bootstrap-variasjonens relative form, bare skalaen.

- **Gjenbruk av befolkningsframskrivning:** `folk_ialt` / `demensandel` for

2026-2050 er uavhengig av bootstrap-vektene (kommer fra SSBs befolkningsframskrivning, ikke fra modellestimeringen) - hentes fra de allerede lagrede `framskrevet_*.rds`-filene i stedet for på nytt fra SSB for hver iterasjon.

9. Retur til slope-modell for framskrivning (rettet en reell bug)

- **Bakgrunn:** appen fikk en "kommunespesifikk trend"-funksjon (tilfeldig

helning på demensandel, tolket som lokal politikk), med en bryter for å fase den ut over T år.

Brukeren oppdaget at når bryteren var AV, ga framskrivningen (basert på den opprinnelige intercept-only `hovedmodell`) en ANNEN verdi enn når bryteren var PÅ med T = 0 år (som skulle bety "ingen trendeffekt", og derfor burde gitt SAMME resultat). Eksempel: Halden, Y_1, 2050 - 3002 (bryter av) vs. 2043 (bryter på, T = 0).

- **Rotårsak:** de to tallene kom fra to FORSKJELLIGE modeller

(`hovedmodell` vs. `hovedmodell_slope`), estimert separat med ULIKE faste effekter (intercept, demensandel-koeffisient) - ikke samme modell med og uten et tillegg. Å bytte modell basert på en bryter som skulle bety "denne ekstra effekten er 0" er derfor feil - det gir en diskontinuitet uansett hvordan T settes til 0.

- **Beslutning (brukerens instruks):** bruk KUN `hovedmodell_slope` for

all framskrivning - fjern `hovedmodell` (intercept-only) fra framskrivningsbruk helt. Dette reverserer den tidligere policyen i punkt 3 ("bruk alltid intercept-only for framskrivning pga. fortegnspørsmålet"), men på en måte som samtidig LØSER fortegnspørsmålet:

- Løsningen er å ANKRE framskrivningen ved kommunens siste observerte (2025) demensandel (se teknisk_dokumentasjon.md pkt. 7 for eksakt formel). Kommunens fulle nivå VED ANKERET (som bruker BÅDE fast og tilfeldig helning) er en KONSTANT som ikke kan eksplodere. All FRAMTIDIG vekst bruker BARE det faste (nasjonale) helningsanslaget - ALDRI kommunens egen tilfeldige helning. Siden det nettopp var kommunens egen (potensielt feil-fortegnede) helning brukt på FRAMTIDIG vekst som var problemet, er faren eliminert når den bare brukes på et fast historisk ankerpunkt.

- Dette gjør "trend-bryteren av" og "trend-bryter på med $T = 0$ " MATEMATISK IDENTISKE per konstruksjon (samme modell, samme formel, $T = 0$ gir bare vekt 0 på det ekstra trend-leddet) - bekreftet numerisk for alle tre variabler (Y_1 , Y_2^* , Y_5) etter rettingen.
- **Konsekvens:** `framskriv_y1.R` / `framskriv_y2_stjerne.R` / `framskriv_y5.R` og `usikkerhet_y1.R` / `usikkerhet_y2_stjerne.R` / `usikkerhet_y5.R` bruker nå alle `hovedmodell_slope` (aldri intercept-only-modellen) for faktisk framskrivning og bootstrap-usikkerhet. Punktestimater og bootstrap-CI er begge regenerert med den nye metoden.

10. Publisering på shinyapps.io (beta)

- **Valg av vertsplattform:** shinyapps.io, gratis-nivå - valgt av brukeren for et raskt, enkelt førsteutkast med en delbar URL til veiledere, uten behov for egen serverdrift. Kjente begrensninger på gratis-nivået: maks 25 aktive timer/måned totalt, appen "sovner" etter ~15 minutters inaktivitet (kort oppstartsforsinkelse ved neste besøk).
- **Kontosikkerhet:** kontoopprettelse og token-kobling (`rsconnect::setAccountInfo()`) ble gjort av brukeren selv, direkte i egen R-konsoll - IKKE av assistenten, siden dette innebærer å taste inn et hemmelig token/secret. Selve opplastingen (`rsconnect::deployApp()`) kunne gjøres av assistenten etterpå, siden kontoinfo da allerede lå lagret lokalt (ikke noe hemmelig som måtte håndteres videre).
- **Minimal opplasting, ikke hele prosjektet:** `app.R` bruker i praksis bare 10 av de 65 filene i `data/ssb/` (~4,5 MB av totalt ~144 MB) - de øvrige er mellomresultater fra `skript/`-pipelinen (rå paneldata, CSV-kopier, ikke-slope-modeller, CV-prediksjoner, plott) som appen ikke leser. Løst med en EKSPLISITT fil-liste til `deployApp(appFiles = ...)` i stedet for å laste opp hele mappen.
 - `.rscignore` **alene var ikke nok:** filen støtter (i motsetning til `.gitignore`) IKKE wildcards eller negasjon - bare ett fast fil-/ mappenavn per linje. Brukes derfor bare til å utelate hele mapper (`skript/`, `dokumentasjon/`), mens det fin-kornede utvalget av hvilke `data/ssb/`-filer som skal med, styres av `appFiles`.
- `skript/` og `dokumentasjon/` **lastes ikke opp** - appen leser dem aldri (se punkt 6), og de har heller ingen verdi for en ekstern bruker av den ferdige appen.