

Teknisk dokumentasjon - modeller og estimering

Dette dokumentet beskriver de statistiske modellene som brukes til å framskrive Y_1 , Y_2^* , Y_4 og Y_5 : likninger, estimeringsprosedyre, kryssvalideringsresultater, framskrivningsmetode og usikkerhetskvantifisering. For BEGRUNNELSENE bak disse valgene (hvorfor Poisson, hvorfor intercept-only i kryssvalideringen men slope-modell i framskrivningen, hvorfor 2010 er utelatt for Y_1 osv.), se beslutningslogg.md.

NB: dette dokumentet er bevisst IKKE tilgjengelig fra selve Shiny-appen (`app.R`) - se punkt 6 i beslutningsloggen.

1. Datagrunnlag

Variabel	Definisjon	Estimeringsperiode	Kommune-år (N)	Kommuner
Y_1	Brukere av hjemmetjenester, i alt	2007-2025, ekskl. 2010	6 337	357
Y_2^*	Y_2 (heldøgnsbolig) + Y_3_a (institusjon, langtid), i alt	2007-2025	5 167	355
Y_4	Gjennomsnittlig timer/uke, hjemmetjenester	2007-2025	6 329	357
Y_5	Sykepleiere, årsverk i alt	2015-2025 (mangler helt 2007-2014)	3 898	357

Alle modeller bruker `demensandel = demens_estimert / folk_ialt` (se `legg_til_demens.R`) og en tilfeldig kommuneeffekt over `kommunenr_2024` (2024-kommunestruktur, se `hent_paneldata_2007_2025.R`).

Demensestimatet beregnes som:

```

demens_estimert(kommune, år) =  $\Sigma$ _(alder, kjønn) [ befolkning(alder, kjønn, kommune, år)
  × prevalensrate(alder, kjønn) ]
  
```

der prevalensratene er faste, aldersgruppe- og kjønnsspesifikke andeler (se `dementia_dic` i `legg_til_demens.R`).

2. Modell Y_1 - hjemmetjenestebrukere (`modell_y1.R`)

Type: Poisson generalisert lineær blandet modell (`lme4::glmer`, log-lenke), befolkning som eksponering (offset).

Likning (hovedmodell):

```
Y_1_a_ialt(k, t) ~ Poisson(mu_kt)
log(mu_kt) = log(folk_ialt_kt) + beta_0 + sum_t y_t * ar_t + beta_1 * demensandel_kt + u_k
u_k ~ N(0, sigma_u^2)
```

Estimerte parametre (hovedmodell, alle tilgjengelige år unntatt 2010):

Parameter	Estimat
Intercept (beta_0)	-3,832
demensandel (beta_1)	34,02
Årseffekter (y_t)	spenner fra -0,047 (2025) til 0,059 (2009), relativt til 2007
Kommune-tilfeldig-intercept, SD (sigma_u)	0,188

Kryssvalidering (leave-one-year-out, alle år):

Modellvariant	RMSE	MAE	Korrelasjon
Kun tilfeldig intercept (brukt til framskrivning)	104,9	51,4	0,9964
Intercept + korrelert helning på demensandel	68,0	34,2	0,9985

Helningsvarianten gir 91 av 357 kommuner en negativ effektiv helning på demensandel - opprinnelig grunnen til at intercept-only-modellen ble brukt til framskrivning, selv om helningsvarianten scorer bedre på CV. ****Denne policyen er reversert**** (se beslutningslogg pkt. 9 og pkt. 7 lenger ned i dette dokumentet): framskrivning bruker nå ALLTID helningsvarianten (`hovedmodell_slope`), men med en ANKRINGSMETODE som gjør at kommunens egen (potensielt feil-fortegnede) helning aldri brukes på framtidig demensandel-vekst - bare på et fast, historisk ankerpunkt. CV-tallene over gjelder fortsatt som en RÅ sammenligning av de to modellvariantene UTEN ankring, og er derfor fortsatt informative for å forstå hvorfor helningsvarianten historisk ble ansett som risikabel.

2010 er utelatt fra estimeringsdataene for denne variabelen (se beslutningslogg pkt. 1).

3. Modell Y_2* - heldøgns omsorg (`modell_y2_stjerne.R`)

Type: samme struktur som Y_1 (Poisson GLMM, log-lenke, befolkning som offset).

Likning:

```
Y_2_stjerne_ialt(k, t) ~ Poisson(mu_kt)
log(mu_kt) = log(folk_ialt_kt) + beta_0 + sum_t y_t * ar_t + beta_1 * demensandel_kt + u_k
```

der `Y_2_stjerne_ialt = Y_2_ialt + Y_3_a_ialt` .

Estimerte parametre (hovedmodell, alle år 2007-2025):

Parameter	Estimat
Intercept (β_0)	-4,956
demensandel (β_1)	30,80
Årseffekter (γ_t)	monotont fallende fra 2010 (0,003) til 2025 (-0,171), relativt til 2009
Kommune-tilfeldig-intercept, SD (σ_u)	0,260

Kryssvalidering (leave-one-year-out, alle år):

Modellvariant	RMSE	MAE	Korrelasjon
Kun tilfeldig intercept (brukt til framskrivning)	35,7	19,2	0,9968
Intercept + korrelert helning på demensandel	46,4	20,7	0,9950

Her er intercept-only-modellen faktisk BEST på kryssvalidering i tillegg til å unngå fortegnspromblemet (95/355 kommuner med negativ effektiv helning i den korrelerte helningsvarianten, 78/355 i den ukorrelerte). **Som for Y_1 er dette likevel ikke lenger avgjørende for framskrivningen:** `hovedmodell_slope` brukes nå ALLTID, ankret ved 2025-nivået (se pkt. 7), slik at fortegnspromblemet ikke kan påvirke framskrivningen uansett hvilken modell som passer best på rå CV.

2010 er IKKE utelatt for denne variabelen - sjekket spesifikt og ikke funnet noe tilsvarende avvik (se beslutningslogg pkt. 1).

4. Modell Y_4 - timer/uke (`modell_y4.R`)

Type: lineær blandet modell (`lme4::lmer` , identitetslenke) - IKKE Poisson, siden Y_4 allerede er et gjennomsnitt (timer/uke per bruker), ikke et antall. Ingen offset.

Likning:

$$Y_{4_ialt}(k, t) = \beta_0 + \sum_t \gamma_t \cdot \text{år}_t + \beta_1 \cdot \text{demensandel}_{kt} + u_k + \varepsilon_{kt}$$

$$u_k \sim N(0, \sigma_u^2), \quad \varepsilon_{kt} \sim N(0, \sigma_\varepsilon^2)$$

Estimerte parametre (hovedmodell, alle år 2007-2025):

Parameter	Estimat
Intercept (β_0)	4,093
demensandel (β_1)	-0,899
Årseffekter (γ_t)	stigende fra 2009 (0,460) til 2022 (1,022), noe fallende mot 2025 (0,937)
Kommune-tilfeldig-intercept, SD (σ_u)	2,105
Residual-SD (σ_ε)	1,774

Kryssvalidering (leave-one-year-out, alle år):

Modellvariant	RMSE	MAE	Korrelasjon
Kun tilfeldig intercept (brukt til framskrivning)	1,77	1,20	0,736
Intercept + korrelert helning på demensandel	1,53	0,98	0,813

Vesentlig svakere prediktiv treffsikkerhet enn de øvrige variablene (forventet - se `modell_y4.R` s egen kommentar om at Y_4 er et gjennomsnitt beregnet over få brukere i mange, særlig små, kommuner). Helningsvarianten har et enda mer utbredt fortegnsproblem enn de andre variablene: 195/357 kommuner (korrelert) / 192/357 (ukorrelert) får en negativ effektiv helning på demensandel.

Forkastet variant: `Y_1_a_ialt` (antall hjemmetjenestemottakere) ble testet som en ekstra, rå forklaringsvariabel på oppfordring. Ga ingen meningsfull forbedring i CV-korrelasjon (~0,735 med og uten), og fikk `demensandel` s koeffisient til å bli enda mer negativ - et tegn på at `Y_1_a_ialt` i stor grad fanger opp kommunestørrelse (kollinearitet), ikke en selvstendig effekt. Ikke tatt i bruk. Koden for dette forsøket ligger fortsatt i `modell_y4.R` (kommentert inn i formlene), men brukes ikke i `framskriv_y4.R` (som ikke er skrevet ennå).

5. Modell Y_5 - sykepleierårsverk (`modell_y5.R`)

Type: lineær blandet modell (`lme4::lmer`) på LOGARITMEN av Y_5 , med befolkning som offset (koeffisient tvunget til 1) - samme multiplikative populasjonsskalering som Poisson-modellene for Y_1/Y_2^* , men med normalfordelte feil på logskala i stedet for Poisson-varians, siden årsverk ikke er et heltall.

Likning:

$$\log(Y_5_ialt(k, t)) = \log(folk_ialt_kt) + \beta_0 + \sum_t \gamma_t \cdot \text{år}_t + \beta_1 \cdot demensandel_kt + u_k + \varepsilon_{kt}$$
$$u_k \sim N(0, \sigma_u^2), \quad \varepsilon_{kt} \sim N(0, \sigma_\varepsilon^2)$$

Estimerte parametre (hovedmodell, alle år 2015-2025):

Parameter	Estimat
Intercept (β_0)	-5,256
demensandel (β_1)	13,83
Årseffekter (γ_t)	stigende fra 2016 (0,016) til 2020 (0,070), fallende mot 2025 (0,031), relativt til 2015
Kommune-tilfeldig-intercept, SD (σ_u)	0,264
Residual-SD (σ_ε)	0,107

Kryssvalidering (leave-one-year-out, alle 11 år):

Modellvariant	RMSE	MAE	Korrelasjon
Kun tilfeldig intercept (brukt til framskrivning)	13,9	5,6	0,9975
Intercept + korrelert helning på demensandel	12,7	4,9	0,9979

God prediktiv treffsikkerhet, på linje med Y_1/Y_2^* . Helningsvarianten: 103/357 kommuner med negativ effektiv helning (korrelert), men bare 10/357 i den UKORRELERTE varianten - vesentlig bedre enn for de andre variablene. Framskrivning bruker likevel samme ankrede `hovedmodell_slope`-metode som Y_1/Y_2^* (se pkt. 7), for konsistens og fordi ankringen uansett gjør fortegnspromblemet irrelevant for selve framskrivningen.

Datadekning: kun 2015-2025 (11 år) har faktiske observasjoner - 2007- 2014 mangler helt i datagrunnlaget. Modellen er derfor trent på et vesentlig kortere tidsvindu enn de andre variablene.

6. Kryssvalideringsmetode (gjelder alle modeller)

Leave-one-year-out (LOYO): for hvert år t i datasettet estimeres modellen på ALLE ANDRE år, og brukes til å predikere år t . Siden alle modellene har årsummyer (`år_f`), har den re-estimerte modellen per definisjon ingen egen koeffisient for det utelatte året. Dette løses med en forenkling:

$$y_t(\text{utelatt år}) \approx \text{gjennomsnitt}(y_t \text{ for alle andre år i treningsdataene})$$

Dette er en tilnærming, ikke en eksakt løsning - se `loyo_cv()`-funksjonen i hvert `modell_*.R`-script. RMSE, MAE og korrelasjon rapporteres både per utelatt år og samlet over alle utelatte år.

7. Framskrivningsmetode (`framskriv_y1.R`, `framskriv_y2_stjerne.R`, `framskriv_y5.R`)

****OPPDATERT METODE** (rettet policy - se beslutningslogg.md, "Retur til slope-modell")**: punkttestimatet bruker nå `hovedmodell_slope` (tilfeldig intercept OG helning på demensandel per kommune), ANKRET ved kommunens siste observerte (2025) demensandel - IKKE en separat intercept-only-modell som tidligere. Se punkt 2 i denne oppdateringen for hvorfor.

Trinn:

- Hent SSBs befolkningsframskrivning (tabell 12882, hovedalternativ
`MMMM = ContentsCode = "Personer"`) for 2026-2050, per kommune, alder og kjønn.
- Beregn framskrevet `demensandel` med SAMME prevalensrater som i historikken.
- Predikér med `hovedmodell_slope`, ANKRET ved kommunens siste observerte (2025) demensandel (`a_k`). Årseffekten for et framtidig år settes til gjennomsnittet av de historiske årseffektene, som før. La `u_k0` og `u_k1` være kommunens tilfeldige intercept og helning:

```

intercept'_k =  $\beta_0 + u_{k0} + (\beta_1 + u_{k1}) \cdot a_k$  (konstant per kommune)
 $\hat{y}_{kt} = \exp( \text{intercept}'_k + \text{gjennomsnitt}(y_t) + \beta_1 \cdot (\text{demensandel}_{kt} - a_k) + \log(\text{folk\_t\_alt}_{kt}) )$ 

```

Hvorfor ankring, og hvorfor dette gjør slope-modellen TRYGG å bruke: `intercept'_k` er en KONSTANT (bygget fra modellens fit VED ankeret) og kan derfor ikke selv eksplodere. All FRAMTIDIG vekst i demensandel bruker BARE det faste, nasjonale helningsanslaget β_1 - ALDRI kommunens egen tilfeldige helning `u_k1`. Det er nettopp bruken av `u_k1` på FRAMTIDIG vekst som tidligere ga et implausibelt fortegn for en andel kommuner (se pkt. 3 i hoveddokumentet) - siden `u_k1` her bare multipliserer et FAST historisk ankerpunkt (ikke en økende fremtidig størrelse), er denne faren eliminert. Uten ankring - dvs. å bruke `u_k1 · demensandel_kt` direkte, eller å bytte mellom en egen intercept-only-modell og denne modellen - oppstår et reelt inkonsistens-problem: de to modellvariantene har ULIKE faste effekter (β_0, β_1), så et brukergrensesnitt som lar brukeren "slå av" en tilfeldig-helning-effekt ved å bytte til en ANNEN modell vil vise et synlig sprang selv når effekten skulle vært 0 %. Dette ble funnet som en reell bug i appen og rettet ved å ALLTID bruke `hovedmodell_slope`, aldri en egen intercept-only-modell, for framskrivning.

4. Glidende overgang fra observert 2025-nivå til modellframskrivning,

for å unngå brå hopp i grafene ved skjøten mellom historikk og framskrivning - nå strukket over HELE framskrivningsperioden (2026-2050) i stedet for bare de første 10 årene, for å unngå et kink i grafen der overgangsvekten tidligere flatet ut brått til 0 i 2036:

```

vekt_t = max(0, 0.9 × (2050 - t) / (2050 - 2026)) for t = 2026..2050
y_predikert_t = vekt_t × y_observert_2025 + (1 - vekt_t) ×  $\hat{y}_{kt}$ 

```

Dette gir 90 % vekt på observert 2025-nivå i 2026, lineært avtagende til 0 % (100 % modell) først i 2050 (siste framskrevne år). Se `glatt_overgang()` i hvert `framskriv_*.R`-script. NB: dette betyr at observert 2025-nivå har en god del gjenværende vekt langt inn i perioden (f.eks. ~45-50 % ved 2036) - en bevisst avveining mellom å unngå kink-artefaktet og hvor lenge ett enkelt historisk datapunkt påvirker framskrivningen.

Kommunespesifikk trend (appen): `app.R` sin `framskriv_trend()` bruker NØYAKTIG samme ankermetode som over, men med en brukerstyrt vekt `vekt_trend(t) = max(0, (T - (t - 2026)) / T)` multiplisert med `u_k1` i stedet for helningsbidraget alltid værende 0 (dvs. dette er en generalisering av pkt. 3 - "standardvisningen" i appen er nøyaktig det samme som `T = 0`). Se kommentarblokken ved `framskriv_trend()` i `app.R`.

Kun ett befolkningsscenario (MMMM) er beregnet så langt - `ALTERNATIV` -variabelen i skriptene kan endres til `"Personer1"` (LLML) eller `"Personer2"` (HHMH) for å beregne alternative scenarier.

8. Kvantifisering av usikkerhet (`usikkerhet_y1.R`, `usikkerhet_y2_stjerne.R`, `usikkerhet_y5.R`)

Metode: Bayesiansk bootstrap PÅ KOMMUNE-NIVÅ, ikke radnivå - dette respekterer panelstrukturen (en kommune, ikke en kommune-år-rad, er enheten som varierer, siden radene innad i en kommune deler samme tilfeldige kommuneeffekt).

For hver av $R = 60$ iterasjoner:

1. **Trekk vektor:** for K kommuner i modelldata, trekk `g_1, ..., g_K` uavhengig fra `Gamma(1, 1)` (= `Exponential(1)`), og normaliser:

$$w_k = (g_k / \sum_j g_j) \times K$$

`g_k / \sum_j g_j` er en eksakt Dirichlet(1,...,1)-trekning (flat prior på simpleksen). Multiplikasjonen med K skalerer opp fra gjennomsnitt $1/K$ til gjennomsnitt 1 - nødvendig fordi `glmer` / `lmer` tolker `weights` som presisjonsvekter (en vekt på $\sim 1/K$ ville kunstig blåst opp den estimerte residual-/tilfeldig-effekt-variansen), ikke som sannsynlighetsvekter. Skaleringen endrer ikke selve Dirichlet-fordelingens relative form, bare dens skala.

2. **Refit:** `w_k` tildeles til ALLE rader for kommune k , og `hovedmodell_slope` (samme `FORMEL_SLOPE` som i `modell_<variabel>.R`) refittes med disse som `weights` i `glmer` / `lmer`.
3. **Framskriv:** den refittede modellens koeffisienter og tilfeldige effekter settes inn i NØYAKTIG samme ankermetode som punkttestimatet (pkt. 7) - inkludert samme glidende overgang mot observert 2025-nivå.
4. Resultatet for denne iterasjonen legges til en midlertidig (kommune $\times$ år)-matrise HOLDT KUN I MINNET.

Etter alle R iterasjoner: 2,5- og 97,5-persentilen beregnes radvis (per kommune $\times$ år) over de R lagrede framskrivningene - dette gir et 95 % konfidensintervall. Persentilene (og punkttestimatet fra den ikke-vektede modellen) lagres; de R RÅ enkeltframskrivningene lagres ALDRI til disk - kun holdt transient i minnet under kjøringen, for å unngå å bygge opp store mellomresultatfiler for noe som uansett bare skal oppsummeres til to tall per (kommune, år).

Gjenbruk av befolkningsframskrivning: `folk_ialt` / `demensandel` for 2026-2050 er uavhengig av bootstrap-vektene (de kommer fra SSBs befolkningsframskrivning, ikke fra modellestimeringen) - hentes fra de allerede lagrede `framskrevet_<variabel>.rds`-filene i stedet for på nytt fra SSB for hver av de 60 iterasjonene.

Eksempel (`Y_1`, Halden, alle 60 iterasjoner konvergente):

År	Punktestimat	95 % KI
2026	1 086,1	[1 083,0 - 1 095,7]
2030	1 124,9	[1 111,0 - 1 155,0]
2040	1 440,1	[1 341,9 - 1 591,4]
2050	2 043,8	[1 753,4 - 2 442,2]

Intervallene er smalt nær 2026 (dominert av den glidende overgangens vekt på det observerte, ikke-tilfeldige 2025-nivået) og videre ut mot 2050 etter hvert som modell-/parameterusikkerheten får dominere.

Viktig begrensning: usikkerheten er KUN beregnet for standard- framskrivningen ($T = 0$ implisitt = 0, dvs. ingen kommunespesifikk trend). Når "Bruk kommunens egen trend" er slått på i appen ($T > 0$, se pkt. 7), vises IKKE noe usikkerhetsbånd - bootstrap er ikke kjørt for $T > 0$ -varianten. Dette er en bevisst avgrensning av omfanget (ikke en bug): trend-varianten ble bygget for å "se hvordan resultatet ser ut" først, før eventuell usikkerhetskvalifisering utvides til den.

R = 60 ble valgt som et praktisk startpunkt (se beslutningslogg pkt. 8)

- kan økes ved å endre `ANTALL_BOOTSTRAP` i hvert `usikkerhet_*.R`-script,

på bekostning av lengre kjøretid (hvert R-refit av `hovedmodell_slope` tar lengre tid enn intercept-only-varianten, pga. flere parametre og en korrelert tilfeldig helning).

9. Kjente begrensninger / videre arbeid

- `Y_3` er ikke modellert som egen variabel (kun som del av `Y_2*`).
- `framskriv_y4.R` er ikke skrevet - `Y_4`'s svake prediktive treffsikkerhet (korrelasjon ~0,74) gjør at videre arbeid her bør vurderes nøye før framskrivning tas i bruk. `Y_4` er heller ikke oppdatert til den nye ankrede slope-metoden (pkt. 7) - bruker fortsatt kun den opprinnelige intercept-only-modellen i `modell_y4.R`, siden ingen framskrivning finnes for denne variabelen ennå.
- Bootstrap-usikkerhet (pkt. 8) er kun beregnet for $T = 0$ (standardframskrivningen) - ikke for den brukerstyrte kommunespesifikke trend-varianten ($T > 0$).
- Kun ett befolkningsscenario (MMMM) er beregnet - LLML, HHMH og Telemarksforskning sine befolkningsframskrivninger er planlagt, men ikke implementert (se "Om"-fanen i appen).
- Estimering av TILBUD av sykepleiere (i tillegg til dagens etterspørselsestimat) er planlagt, med metodikk fra SSB-rapporten RAPP 2026/18 (se "Om"-fanen) - ikke påbegynt.
- LOYO-kryssvalideringens håndtering av årseffekt for utelatt år (gjennomsnitt av andre år) er en forenkling - se pkt. 6.